

TRABAJO PRÁCTICO GRUPAL

INTRODUCCIÓN A BIG DATA

Documento Teórico

Materia: Base de Datos 2

Tema: Big Data

Integrantes: Santino Cataldo y Sebastián Fernández Ruhl

Año: 2026

Índice

1. Introducción

2. ¿Por qué aparece Big Data?

2.1. Limitaciones del modelo relacional

2.2. El quiebre: la Web 2.0

3. Definición de Big Data

4. Las 5 V del Big Data

4.1. Volumen

4.2. Velocidad

4.3. Variedad

4.4. Veracidad

4.5. Valor

5. Tipos de datos

6. RDBMS Tradicional vs. Big Data

7. Fuentes del Big Data

8. Ecosistema tecnológico

8.1. Apache Hadoop y HDFS

8.2. MapReduce

8.3. Apache Spark

8.4. Apache Kafka

8.5. Servicios Cloud

9. Casos de uso reales

10. Consideraciones éticas y legales

11. Conclusiones

12. Referencias bibliográficas

1. Introducción

El presente documento tiene como objetivo profundizar en el concepto de Big Data, un paradigma que ha transformado radicalmente la forma en que las organizaciones gestionan, procesan y extraen valor de los datos. En un mundo donde la producción de información crece de manera exponencial —se estima que en 2025 se generaron aproximadamente 221 Zettabytes de datos a nivel global (Statista, 2025)—, las herramientas y arquitecturas tradicionales de bases de datos resultan insuficientes para abordar los desafíos que esto plantea.

A lo largo de este trabajo, se analizará el contexto histórico que dio origen al paradigma Big Data, sus características fundamentales expresadas a través de las "5 V", las tecnologías clave que componen su ecosistema (Hadoop, Spark, Kafka, entre otras), y los casos de uso reales que demuestran su impacto en industrias tan diversas como la salud, las finanzas, el comercio electrónico y la agricultura de precisión.

Además del material bibliográfico proporcionado por la cátedra, se incorpora investigación adicional proveniente de fuentes académicas y profesionales que permiten ampliar la comprensión del tema y contextualizarlo en el panorama tecnológico actual.

2. ¿Por qué aparece Big Data?

Durante décadas, el estándar de la industria del almacenamiento y procesamiento de datos descansaba sobre pilares muy claros: SQL como interfaz unificada, con tablas de filas y columnas definidas por esquemas fijos, y una arquitectura centralizada donde un único servidor actuaba como motor de toda la lógica de almacenamiento y consulta (Mayer-Schönberger & Cukier, 2013).

2.1. Limitaciones del modelo relacional

Los sistemas de gestión de bases de datos relacionales (RDBMS) presentan limitaciones fundamentales cuando enfrentan los volúmenes y la velocidad de datos que caracterizan al mundo digital contemporáneo:

Volúmenes gigantescos: Sistemas pensados para Gigabytes colapsan ante escalas exponencialmente mayores. Los volúmenes actuales se miden en Terabytes (TB), Petabytes (PB) e incluso Exabytes (EB).

Datos en tiempo real: La arquitectura tradicional de "almacenamiento-luego-procesamiento" no responde adecuadamente ante flujos de datos que exigen análisis inmediato, como la detección de fraudes bancarios o la personalización instantánea de experiencias de usuario.

Datos no estructurados: El software relacional exige que el dato se adapte a la tabla mediante un esquema rígido (schema-on-write). Sin embargo, la realidad actual entrega datos en formatos diversos: texto libre, imágenes, video, audio, datos de sensores.

Límites de escalabilidad: La escalabilidad vertical (Scale-Up) —agregar más potencia a un único servidor— tiene un límite físico y un costo prohibitivo. La alternativa de escalabilidad horizontal (Scale-Out) con bases de datos relacionales resulta ineficiente debido a que los JOINS distribuidos destruyen el rendimiento.

2.2. El quiebre: la Web 2.0

El punto de inflexión llegó con la denominada Web 2.0: la proliferación de redes sociales (Facebook, Twitter, Instagram), dispositivos móviles inteligentes (smartphones, tablets) y el Internet de las Cosas (IoT) produjo una explosión masiva e inmanejable de datos. Solo Facebook genera aproximadamente 4 Petabytes de datos por día, mientras que YouTube recibe 720.000 horas de video diariamente (Gantz & Reinsel, 2012).

Esta transformación no fue gradual, sino exponencial. La humanidad generó más datos entre 2020 y 2025 que en toda su historia anterior combinada. Este fenómeno hizo evidente que se necesitaba un nuevo paradigma tecnológico: Big Data.

3. Definición de Big Data

Big Data se define como el conjunto de tecnologías, métodos y arquitecturas diseñadas para capturar, almacenar, procesar y analizar volúmenes de datos tan grandes y complejos que no pueden manejarse eficientemente con herramientas tradicionales (Laney, 2001).

Sin embargo, reducir Big Data a simplemente "muchos datos" es un error conceptual. Big Data implica una transformación paradigmática en la ingeniería de datos que abarca: procesamiento a gran escala, respuesta a alta velocidad, diversidad absoluta de formatos, cómputo distribuido en clústeres de máquinas commodity y, sobre todo, la capacidad de extraer valor e insights accionables de los datos crudos.

Según el informe de McKinsey Global Institute (2011), Big Data se refiere a "datasets cuyo tamaño está más allá de la capacidad de las herramientas de software de bases de datos típicas para capturar, almacenar, gestionar y analizar". Esta definición pone énfasis en la relatividad del concepto: lo que hoy consideramos Big Data será considerado "normal" mañana, a medida que las herramientas evolucionen.

4. Las 5 V del Big Data

Las características fundamentales del Big Data se expresan comúnmente a través de las "5 V", un modelo originalmente propuesto por Doug Laney (2001) con 3 V (Volumen, Velocidad, Variedad) y luego ampliado por la industria a 5 V con la incorporación de Veracidad y Valor.

4.1. Volumen

La primera y más evidente característica del Big Data es la cantidad masiva de información que se genera y almacena. No se mide en Gigabytes (GB), sino en Terabytes (TB), Petabytes (PB), Exabytes (EB) y, a menudo, Zettabytes (ZB). Para dimensionar en escala binaria académica: 1 TB equivale a 1.024 GB, 1 PB a 1.024 TB, 1 EB a 1.024 PB, y 1 ZB a 1.024 EB. Esto significa que un Zettabyte equivale a 1.099.511.627.776 Gigabytes (o un billón de Gigabytes en escala decimal, es decir, 10^{12} GB).

Este volumen extremo excede la capacidad de almacenamiento y procesamiento de los sistemas de bases de datos tradicionales, que no fueron diseñados para escalar a esta magnitud. Requiere infraestructuras distribuidas y técnicas de procesamiento paralelas para ser gestionado eficazmente. Se estima que Google procesa 20 Petabytes diarios solo para indexar la web (Dean & Ghemawat, 2004).

4.2. Velocidad

La Velocidad define la rapidez con la que los datos son generados, recopilados y, lo más importante, procesados. No se trata solo de la acumulación, sino de la capacidad de analizar y reaccionar a la información casi en tiempo real. Esto es crucial para la detección de fraudes financieros, la gestión de mercados bursátiles o la personalización instantánea de experiencias de usuario.

Los sistemas de Big Data están diseñados para manejar flujos de datos continuos (streaming), extrayendo valor en el momento justo para la toma de decisiones ágil. Se estima que se procesan 3,81 Petabytes por segundo de forma sostenida a nivel global (Statista, 2025).

4.3. Variedad

Más allá de la cantidad, Big Data se define por la inmensa diversidad de formatos y tipos de datos. A diferencia de las bases de datos tradicionales que se limitan principalmente a datos estructurados, el ecosistema de Big Data procesa un espectro mucho más amplio:

Datos estructurados (~20%): Organizados en esquemas predefinidos y fijos, como tablas con filas y columnas. Ejemplos: hojas de cálculo, bases de datos SQL, sistemas ERP.

Datos semi-estructurados (~10%): Tienen alguna estructura pero no un esquema rígido. Usan etiquetas o marcadores para organizar elementos. Ejemplos: JSON, XML, archivos de log.

Datos no estructurados (~70%): Sin un formato predefinido. Representan la mayor parte de los datos generados hoy. Ejemplos: texto libre, imágenes, audio, video, publicaciones en redes sociales.

4.4. Veracidad

La Veracidad se refiere a la calidad, exactitud y fiabilidad de los datos. En un entorno donde la información proviene de múltiples fuentes, muchas de ellas no controladas, la probabilidad de encontrar datos imprecisos, inconsistentes o sesgados es alta. Se estima que aproximadamente el 27% de los datos en organizaciones grandes contiene errores significativos (Experian, 2023).

Asegurar la veracidad implica procesos de limpieza (data cleaning), validación, estandarización y gestión de la gobernanza de datos para garantizar que la información sea digna de confianza y útil para la toma de decisiones.

4.5. Valor

El Valor es el objetivo final y la razón de ser del Big Data. No es suficiente con recolectar, almacenar y procesar grandes volúmenes de datos; la clave reside en la capacidad de transformar esa información cruda en conocimiento accionable. Este valor se manifiesta en la mejora de la toma de decisiones, la optimización de procesos, la identificación de nuevas oportunidades de negocio y la creación de ventaja competitiva.

Extraer valor implica aplicar técnicas de análisis avanzados, machine learning e inteligencia artificial para descubrir patrones ocultos y predecir tendencias. El mercado global de Big Data y analytics alcanzó los \$274 mil millones en 2026 (IDC, 2026).

5. Tipos de datos

Como se mencionó en la sección de Variedad, el ecosistema de Big Data procesa tres grandes categorías de datos. La capacidad de integrar y analizar esta heterogeneidad es fundamental para obtener una visión completa de cualquier fenómeno o negocio.

Categoría	Características	Ejemplos
Estructurados	Esquema fijo, tablas con filas y columnas	SQL, Excel, ERP, CRM
Semi-estructurados	Estructura parcial, etiquetas o marcadores	JSON, XML, Logs, Emails
No estructurados	Sin formato predefinido, requieren técnicas avanzadas	Imágenes, Video, Audio, Texto libre

6. RDBMS Tradicional vs. Big Data

La siguiente tabla comparativa ilustra las diferencias fundamentales entre los sistemas de bases de datos relacionales tradicionales y las arquitecturas de Big Data:

Característica	RDBMS Tradicional	Big Data / NoSQL
Escalabilidad	Vertical (Scale-Up)	Horizontal (Scale-Out)
Datos	Estructurados, esquema rígido	Estructurados, semi y no estructurados
Tamaño	GB a pocos TB	TB, PB hasta EB
Procesamiento	Centralizado	Distribuido en paralelo
Esquema	Schema-on-Write	Schema-on-Read
Consistencia	ACID	BASE (Eventually Consistent)
Costo	Hardware especializado, licencias	Hardware commodity, open-source

Es importante destacar que los RDBMS no desaparecen con la llegada de Big Data. Siguen siendo la mejor opción para sistemas transaccionales donde la consistencia ACID es crítica, como sistemas bancarios o de inventario. Big Data complementa estos sistemas, no los reemplaza (Stonebraker et al., 2010).

7. Fuentes del Big Data

Los datos que alimentan el ecosistema de Big Data provienen de tres grandes categorías de fuentes:

Human-Generated (Generados por humanos): Publicaciones en redes sociales, videos, clics, búsquedas web, correos electrónicos, fotografías y cualquier dato generado por la interacción consciente de personas con entornos digitales. Solo Twitter/X genera aproximadamente 500 millones de tweets por día.

Machine-to-Machine / IoT: Sensores, wearables, dispositivos GPS, cámaras de vigilancia y dispositivos conectados que transmiten datos de forma autónoma las 24 horas sin mediación humana. Se estima que hay 75 mil millones de dispositivos IoT conectados a nivel global en 2025 (Statista, 2025). Un automóvil conectado genera aproximadamente 25 GB de datos por hora de conducción.

Log / System Generated: Archivos de texto generados automáticamente por servidores, bases de datos y sistemas operativos para registrar eventos, errores, métricas de rendimiento y auditoría. Un servidor web de alto tráfico puede generar hasta 1 TB de logs por día.

8. Ecosistema tecnológico

El ecosistema de Big Data está compuesto por un conjunto de herramientas y frameworks, en su mayoría open-source, que trabajan de forma complementaria para resolver los desafíos de almacenamiento, procesamiento y análisis de datos masivos.

8.1. Apache Hadoop y HDFS

Apache Hadoop es el framework fundacional del ecosistema Big Data. Desarrollado originalmente por Doug Cutting y Mike Cafarella inspirados en los papers de Google sobre Google File System (GFS) y MapReduce, Hadoop permite el almacenamiento distribuido y el procesamiento paralelo de grandes volúmenes de datos utilizando hardware commodity (White, 2015).

El sistema de archivos distribuido de Hadoop (HDFS - Hadoop Distributed File System) divide cada archivo en bloques de 128 MB que se distribuyen y replican (factor de replicación 3 por defecto) en múltiples nodos del clúster, proporcionando tolerancia a fallos automática. La arquitectura se basa en un modelo maestro-esclavo: un NameNode gestiona los metadatos y múltiples DataNodes almacenan los bloques de datos.

Un principio fundamental de HDFS es la "Data Locality": en lugar de mover los datos al procesamiento, el procesamiento viaja al dato, minimizando la transferencia de red y optimizando el rendimiento.

8.2. MapReduce

MapReduce es el paradigma de procesamiento distribuido de Hadoop. Funciona en cuatro etapas: (1) Split: los datos de entrada se dividen en fragmentos; (2) Map: cada nodo procesa su fragmento de forma independiente generando pares clave-valor; (3) Shuffle: los resultados intermedios se agrupan por clave y se redistribuyen; (4) Reduce: se combinan los valores de cada clave para producir el resultado final (Dean & Ghemawat, 2004).

8.3. Apache Spark

Apache Spark es un motor de procesamiento que puede ser hasta 100 veces más rápido que MapReduce gracias a su procesamiento in-memory. A diferencia de MapReduce, que escribe resultados intermedios en disco, Spark mantiene los datos en memoria RAM, reduciendo drásticamente la latencia. Spark soporta múltiples paradigmas: procesamiento batch, streaming en tiempo real, machine learning (MLlib) y procesamiento de grafos (GraphX) (Zaharia et al., 2016).

8.4. Apache Kafka

Apache Kafka es una plataforma de streaming distribuido diseñada para la ingestión de datos en tiempo real. Puede manejar millones de eventos por segundo con baja latencia, actuando como un sistema de mensajería pub-sub altamente escalable. Es utilizado por empresas como LinkedIn, Netflix y Uber para procesar flujos de datos continuos.

8.5. Servicios Cloud

Los principales proveedores de servicios en la nube ofrecen soluciones gestionadas de Big Data que eliminan la complejidad de administrar la infraestructura: Amazon Web Services (EMR, Redshift), Google Cloud (BigQuery, Dataflow) y Microsoft Azure (HDInsight, Synapse Analytics). Estos servicios proporcionan escalabilidad elástica bajo demanda, permitiendo que las organizaciones paguen solo por los recursos que utilizan.

9. Casos de uso reales

Big Data tiene aplicaciones transformadoras en prácticamente todas las industrias:

Salud: Diagnóstico asistido por inteligencia artificial, predicción de pandemias mediante análisis de patrones epidemiológicos, análisis genómico personalizado para tratamientos a medida, y monitoreo de pacientes en tiempo real mediante dispositivos IoT.

Finanzas: Detección de fraude en tiempo real analizando patrones de transacciones, trading algorítmico de alta frecuencia, scoring crediticio basado en machine learning que considera variables no tradicionales, y cumplimiento regulatorio automatizado.

E-Commerce: Sistemas de recomendación personalizados como los de Amazon y Netflix, análisis de comportamiento de compra, optimización dinámica de precios y gestión predictiva de inventarios.

Smart Cities: Gestión de tráfico inteligente basada en datos de sensores y GPS, monitoreo ambiental en tiempo real, optimización del consumo energético y mejora de servicios públicos como transporte y recolección de residuos.

Agro-Tech: Agricultura de precisión utilizando datos de sensores IoT, drones y satélites, predicción climática localizada, optimización de riego y fertilización, y detección temprana de plagas mediante análisis de imágenes.

10. Consideraciones éticas y legales

El poder del Big Data trae consigo responsabilidades éticas significativas. La recopilación masiva de datos personales plantea preguntas fundamentales sobre privacidad, consentimiento informado y uso responsable de la información. En Argentina, la Ley 25.326 de Protección de Datos Personales establece el marco legal para la gestión de datos personales, mientras que a nivel internacional el GDPR (Reglamento General de Protección de Datos) de la Unión Europea se ha convertido en referencia global.

Entre los principales desafíos éticos se encuentran: la re-identificación de datos supuestamente anonimizados mediante técnicas de cruce de información, el sesgo algorítmico que puede perpetuar discriminaciones sociales, la falta de transparencia en la toma de decisiones

automatizadas, y la concentración del poder de datos en pocas corporaciones tecnológicas. El rol del profesional de datos como guardián ético de la información se vuelve cada vez más relevante.

11. Conclusiones

A lo largo de este trabajo hemos analizado cómo Big Data representa mucho más que una tendencia tecnológica: es un cambio de paradigma en la forma en que la humanidad genera, almacena y extrae conocimiento de los datos. Las conclusiones principales del grupo son:

- Los RDBMS no desaparecen, pero Big Data resuelve problemas que las herramientas tradicionales no pueden abordar, especialmente en escala, velocidad y variedad de datos.
- Las 5 V (Volumen, Velocidad, Variedad, Veracidad y Valor) constituyen el marco conceptual fundamental para comprender las características y desafíos del Big Data.
- El ecosistema tecnológico de Hadoop y Spark, junto con herramientas complementarias como Kafka, Hive y los servicios cloud, proporcionan la infraestructura necesaria para el procesamiento distribuido a gran escala.
- El verdadero poder del Big Data no reside en la acumulación de datos, sino en la capacidad de extraer valor accionable: datos sin análisis son simplemente ruido.
- La democratización del acceso a herramientas de Big Data a través de la nube y la inteligencia artificial está abriendo posibilidades para organizaciones de todos los tamaños, no solo para las grandes corporaciones tecnológicas.
- Las consideraciones éticas y legales son inseparables del desarrollo tecnológico. Los profesionales de datos tienen una responsabilidad fundamental en garantizar el uso responsable y transparente de la información.

12. Referencias bibliográficas

Material base proporcionado por la cátedra:

Tocaimaza, S. (2026). Introducción a Big Data [Diapositivas de clase]. Base de Datos 2, Universidad.

Fuentes adicionales:

- Dean, J., & Ghemawat, S. (2004). MapReduce: Simplified Data Processing on Large Clusters. Proceedings of the 6th USENIX Symposium on Operating Systems Design and Implementation (OSDI), 137-150. <https://research.google/pubs/pub62/>
- Gantz, J., & Reinsel, D. (2012). The Digital Universe in 2020: Big Data, Bigger Digital Shadows, and Biggest Growth in the Far East. IDC. <https://www.emc.com/leadership/digital-universe/2012iview/>
- Laney, D. (2001). 3D Data Management: Controlling Data Volume, Velocity and Variety. META Group Research Note. <https://blogs.gartner.com/doug-laney/>
- Mayer-Schönberger, V., & Cukier, K. (2013). Big Data: A Revolution That Will Transform How We Live, Work, and Think. Houghton Mifflin Harcourt.
- McKinsey Global Institute. (2011). Big data: The next frontier for innovation, competition, and productivity. <https://www.mckinsey.com/business-functions/mckinsey-digital/>
- Statista. (2025). Volume of data/information created, captured, copied, and consumed worldwide. <https://www.statista.com/statistics/871513/>
- Stonebraker, M., Abadi, D., DeWitt, D. J., Madden, S., Paulson, E., Pavlo, A., & Rasin, A. (2010). MapReduce and parallel DBMSs: friends or foes? Communications of the ACM, 53(1), 64-71.
- White, T. (2015). Hadoop: The Definitive Guide (4th ed.). O'Reilly Media.
- Zaharia, M., Xin, R. S., Wendell, P., Das, T., Armbrust, M., Dave, A., ... & Stoica, I. (2016). Apache Spark: A Unified Engine for Big Data Processing. Communications of the ACM, 59(11), 56-65. <https://doi.org/10.1145/2934664>