

BASE DE DATOS 2 • TRABAJO PRÁCTICO GRUPAL

GUÍA DE DEFENSA ORAL Y SPEECH COORDINADO

Introducción a Big Data — Planificación y Guión Paso a Paso (14 Diapositivas)

INTEGRANTES / EXPOSITORES:

Santino Cataldo y Sebastián Fernández Ruhl

AÑO 2026

1. Organización del Equipo y Razón del Reparto 50/50

Para garantizar una exposición fluida, dinámica y equilibrada ante el docente, el contenido de la presentación se ha dividido estrictamente en una proporción del 50/50. Esta separación no es arbitraria, sino que sigue una coherencia lógica de ingeniería y roles:

Santino Cataldo (Especialista en el Problema, Datos y Comparativa): Se encarga de estructurar el contexto histórico y la problemática. Introduce por qué la arquitectura tradicional colapsa (Web 2.0 y RDBMS), explica la Variedad a través de la clasificación de los tipos de datos (20% estructurados, 10% semi, 70% no estructurados) y expone la comparativa directa SQL vs. Big Data, cerrando con el impacto de la escala en el mundo real. Su enfoque está en la identificación de problemas y categorización teórica.

Sebastián Fernández Ruhl (Especialista en el Paradigma, Ecosistema y Tecnología): Se encarga de dar la solución técnica. Define formalmente qué es Big Data, expone las 5 V, detalla físicamente las fuentes de datos (Humanos, Máquinas y Logs), analiza en profundidad los frameworks principales (Hadoop, Spark y Kafka) y el funcionamiento de la computación distribuida (HDFS y MapReduce), cerrando con las conclusiones del equipo. Su enfoque está en la arquitectura, la ingeniería de infraestructura y el procesamiento distribuido.

Esta distribución garantiza que cada expositor domine un área conceptual completa y tenga un hilo conductor claro. De esta forma, se eliminan los saltos desorganizados de orador a mitad de un tema y se evita que uno pise o repita conceptos del otro.

Aunque Santino presenta 8 diapositivas y Sebastián 6, el tiempo de exposición real está equilibrado en una proporción de aproximadamente 6,75 minutos para Santino y 7,25 minutos para Sebastián (para un tiempo total estimado de 14 minutos). Esto se debe a que Sebastián aborda diapositivas técnicas de alta densidad (como el ecosistema de tecnologías y la arquitectura detallada de HDFS y MapReduce), que demandan una explicación más pausada e individual.

2. Guión Detallado Diapositiva por Diapositiva

Slide 1: Portada y Presentación

EXPOSITOR: SANTINO CATALDO

RESUMEN VISUAL DE SOPORTE: Meta-pill con los expositores, título "BIG DATA" e impacto visual Neo-Brutalista de datos.

GUIÓN RECOMENDADO:

Buenas tardes a todos y al profesor. Mi nombre es Santino Cataldo, y junto a mi compañero Sebastián Fernández Ruhl, vamos a presentar nuestro Trabajo Práctico sobre Big Data y su ecosistema tecnológico para la materia Base de Datos 2.

Hoy en día se producen aproximadamente 221 Zettabytes de datos al año a nivel mundial, lo que

equivale a unos 402 millones de Terabytes de información nueva cada día. En esta presentación queremos explicar no solo por qué surgió este volumen descomunal, sino cómo la ingeniería de software y hardware tuvo que reinventarse por completo para poder capturarlo, procesarlo y, lo más importante, extraer valor real de él.

Para entender de manera intuitiva el tamaño real de lo que estamos hablando, Sebastián pasará a la siguiente diapositiva.

Slide 2: La Inmensidad del Dato (Los 21 Ceros)

EXPOSITOR: SANTINO CATALDO

RESUMEN VISUAL DE SOPORTE: Bloque brutalista verde lima gigante que cruza la pantalla con los 21 ceros de un Zettabyte.

GUIÓN RECOMENDADO:

Queremos arrancar dimensionando los números que maneja el Big Data. Un solo Zettabyte es una cifra colosal con 21 ceros: un 1 seguido de veintiún ceros. Para ponerlo en perspectiva, equivale a mil millones de Terabytes. Una escala monumental que define la biósfera digital en la que vivimos. Para entender cómo se compara con lo cotidiano, Sebastián pasará a la escala comparativa.

Slide 3: La Escala Comparativa (TB, PB, EB, ZB)

EXPOSITOR: SANTINO CATALDO

RESUMEN VISUAL DE SOPORTE: Tira comparativa horizontal de 4 columnas (TB -> PB -> EB -> ZB) con multiplicadores de x1.024.

GUIÓN RECOMENDADO:

En bases de datos y sistemas, las unidades crecen de forma binaria multiplicando por 1.024. En pantalla vemos los pesos comparativos:

- *1 Terabyte (TB) es el "peso de una hormiga" (1.024 Gigabytes), la capacidad típica de una notebook actual.*
- *1 Petabyte (PB) es el "peso de un edificio" (1.024 Terabytes). Si lo grabáramos en CDs y los apiláramos, la torre física alcanzaría la altura del Empire State.*
- *1 Exabyte (EB) es el "peso de la historia" (1.024 Petabytes). Equivale a todas las palabras escritas y habladas por los seres humanos en toda la historia de la humanidad.*
- *1 Zettabyte (ZB) es el "peso de un planeta" (1.024 Exabytes). Para dimensionar los 221 ZB anuales que producimos hoy: si cada TB fuera un disco de 10 cm, la pila de discos iría y volvería a la Luna 28 veces.*

Esta inmensidad nos obliga a buscar un nuevo paradigma. Veamos ahora el quiebre de la Web 2.0.

Slide 4: ¿Por qué aparece Big Data? Contexto Histórico

EXPOSITOR: SANTINO CATALDO

RESUMEN VISUAL DE SOPORTE: Diapositiva verde lima que repasa el monopolio de SQL y el quiebre de la Web 2.0.

GUIÓN RECOMENDADO:

Durante más de cuarenta años, el almacenamiento y procesamiento de datos estuvo dominado por un estándar muy claro y eficiente: el modelo relacional tradicional, con el lenguaje SQL como interfaz unificada de esquemas rígidos y una arquitectura centralizada donde un único servidor concentraba toda la lógica de almacenamiento y consulta.

Este modelo era ideal para transacciones comerciales estructuradas de escala corporativa. Sin embargo, el gran punto de quiebre llegó con la denominada Web 2.0: la masificación de los teléfonos inteligentes, las redes sociales de escala global y el Internet de las Cosas (IoT). De repente, los datos dejaron de generarse únicamente en los sistemas internos de las empresas y pasaron a ser creados continuamente, las 24 horas del día, por miles de millones de usuarios en todo el planeta.

Esta explosión de volumen y diversidad generó un cuello de botella tecnológico que expuso las limitaciones estructurales de los motores tradicionales, como detallaremos en la siguiente diapositiva.

Slide 5: Limitaciones del Modelo Relacional

EXPOSITOR: SANTINO CATALDO

RESUMEN VISUAL DE SOPORTE: Diapositiva gris claro que detalla las limitaciones: Volumen, Tiempo Real, No estructurados y Escalabilidad.

GUIÓN RECOMENDADO:

¿Por qué colapsa el modelo relacional tradicional en esta nueva era digital? Lo podemos resumir en cuatro limitaciones de ingeniería fundamentales:

- 1. Volúmenes Gigantescos: Los motores relacionales tradicionales se concibieron para gestionar escalas de Gigabytes o a lo sumo pocos Terabytes. Al pasar a escalas de Petabytes, las operaciones de almacenamiento, indexación y búsqueda centralizada colapsan.*
- 2. Datos en Tiempo Real: El paradigma tradicional de "guardar primero y procesar después" no puede responder ante flujos de datos rápidos que exigen latencias de milisegundos para su*

análisis inmediato.

3. Datos No Estructurados: El software relacional requiere definir estrictamente el esquema de tablas antes de escribir (técnica llamada "Schema-on-Write"). No obstante, el 80% de los datos generados hoy son desestructurados.

4. Límites de Escalabilidad: La escalabilidad vertical (comprar un servidor más grande) tiene un límite físico de ingeniería y costos prohibitivos. La alternativa de escalabilidad horizontal con bases de datos relacionales resulta ineficiente porque realizar JOINS distribuidos entre múltiples servidores destruye el rendimiento por la red.

Para explicarnos cómo se resolvió esta crisis técnica y definir formalmente el nuevo paradigma, le cederé la palabra a Sebastián.

Slide 6: ¿Qué es Big Data? Definición de Paradigma

EXPOSITOR: SEBASTIÁN FERNÁNDEZ RUHL

RESUMEN VISUAL DE SOPORTE: Definición de Big Data (Laney / McKinsey) y pastillas con los principios del paradigma.

GUIÓN RECOMENDADO:

Gracias, Santino. Como bien detallabas, ante estas limitaciones insalvables para el modelo relacional nace Big Data.

Es fundamental aclarar un error conceptual común: Big Data no es simplemente tener muchos datos guardados. Técnicamente, es un conjunto de tecnologías, métodos y arquitecturas de hardware y software específicamente diseñadas para jugar a otra escala. Permite capturar, almacenar y analizar datos que, por su volumen, velocidad o complejidad, resultan completamente inmanejables para los sistemas tradicionales.

Representa un cambio de paradigma de ingeniería en tres aspectos clave: pasamos del procesamiento centralizado en un supercomputador al cómputo distribuido en clústeres de servidores económicos de bajo costo; adoptamos el procesamiento en paralelo como regla; y cambiamos el diseño de esquemas previos por la técnica de "Schema-on-Read", donde los datos se almacenan en su formato nativo crudo y se les da estructura únicamente en el momento de la consulta.

Para operativizar y caracterizar técnicamente este paradigma, la industria consolidó un modelo conocido como las 5 V, que analizamos en la siguiente diapositiva.

Slide 7: Las 5 V del Big Data

EXPOSITOR: SEBASTIÁN FERNÁNDEZ RUHL

RESUMEN VISUAL DE SOPORTE: Diapositiva verde lima con el strip de las 5 Vs (Volumen, Velocidad, Variedad, Veracidad, Valor).

GUIÓN RECOMENDADO:

Las 5 V resumen de forma impecable las dimensiones del desafío técnico de Big Data:

- *Volumen: La cantidad masiva de información acumulada. Hablamos de clústeres que superan holgadamente los Exabytes de datos.*
- *Velocidad: El flujo continuo y la rapidez de generación y procesamiento. Si no somos capaces de analizar los datos en tiempo real (por ejemplo, telemetría o detección de fraude en transacciones), el valor del dato expira.*
- *Variedad: La mezcla absoluta de formatos. Como explicó Santino, ya no procesamos solo tablas estructuradas, sino texto libre, JSON, audio y video de forma simultánea.*
- *Veracidad: La calidad de la información. Debido a la complicidad de fuentes no controladas, los datos vienen con mucho ruido y errores (un 27% en promedio contiene fallas). Se requieren pipelines robustos de limpieza y gobernanza.*
- *Valor: La V más crítica. Consiste en la capacidad de transformar esa inmensa masa de datos en insights accionables, ventajas competitivas o modelos predictivos de Inteligencia Artificial. Almacenar datos sin analizar es simplemente ruido.*

A continuación, Santino nos va a detallar cómo clasificamos esta inmensa variedad en la práctica.

Slide 8: Tipos de Datos (Variedad en Detalle)

EXPOSITOR: SANTINO CATALDO

RESUMEN VISUAL DE SOPORTE: Clasificación de datos en Estructurados (20%), Semi-estructurados (10%) y No Estructurados (70%).

GUIÓN RECOMENDADO:

Retomando la V de Variedad, en la ingeniería de datos contemporánea clasificamos la información en tres grandes categorías según su flexibilidad estructural:

- 1. Datos Estructurados (20%): Tienen un esquema rígido, predefinido y de longitud fija. Son los que dominamos en las bases de datos relacionales tradicionales, hojas de cálculo SQL, y sistemas transaccionales ERP o CRM.*
- 2. Datos Semi-estructurados (10%): No se adaptan a una tabla estructurada, pero contienen marcadores, etiquetas o metadatos jerárquicos que permiten organizar sus elementos. Los estándares globales aquí son JSON, XML, correos electrónicos y archivos de log de servidores.*

3. *Datos No Estructurados (70%): Representan la mayor tasa de crecimiento del planeta. Son datos sin ningún formato predefinido: videos, archivos de audio, fotos de redes sociales o texto libre de documentos escaneados. Para procesarlos y buscar patrones dentro de ellos, requerimos frameworks especializados e Inteligencia Artificial.*

Veamos ahora una comparación conceptual consolidada entre ambos paradigmas.

Slide 9: RDBMS Tradicional vs. Big Data / NoSQL

EXPOSITOR: SANTINO CATALDO

RESUMEN VISUAL DE SOPORTE: Tabla comparativa en verde lima detallando Escalabilidad, Datos, Procesamiento, Esquema, etc.

GUIÓN RECOMENDADO:

En esta tabla comparativa podemos apreciar los dos mundos de manera clara. Mientras los RDBMS se enfocan en escalabilidad vertical, consistencia de transacciones estricta (ACID) y esquemas definidos en la escritura, las herramientas de Big Data adoptan escalabilidad horizontal, esquemas en la lectura, procesamiento paralelo distribuido en clústeres y consistencia eventual del tipo BASE.

Queremos dejar un punto muy en claro: Big Data no viene a reemplazar a los motores de bases de datos relacionales. Para registrar transacciones contables, bancarias o de inventario crítico, los RDBMS con consistencia ACID siguen siendo obligatorios e insustituibles. Big Data es el complemento ideal para la analítica avanzada y la explotación masiva de datos.

Ahora, Sebastián nos va a detallar físicamente de dónde provienen estas fuentes masivas de información.

Slide 10: Fuentes del Big Data

EXPOSITOR: SEBASTIÁN FERNÁNDEZ RUHL

RESUMEN VISUAL DE SOPORTE: Diapositiva gris claro detallando Generados por Humanos, Máquinas / IoT y Logs / Sistemas.

GUIÓN RECOMENDADO:

Gracias, Santino. Para diseñar una arquitectura capaz de procesar estos volúmenes, primero debemos ver su origen. Las fuentes de Big Data se agrupan en tres grandes categorías:

1. Generados por Humanos: Los datos que creamos conscientemente al interactuar en internet. Búsquedas, clics, posteos en redes sociales, videos de YouTube. Solo Facebook ingiere 4 Petabytes diarios y Twitter procesa 500 millones de tweets cada día.

2. Máquinas / IoT (Internet de las Cosas): Datos generados autónomamente por dispositivos inteligentes conectados a internet: sensores, GPS, wearables. Un automóvil conectado genera 25 Gigabytes de telemetría por hora.

3. Logs / Sistemas: Registros automáticos de actividad que los servidores crean para auditoría. Un servidor web de alto tráfico genera fácilmente 1 Terabyte de logs de texto diario, de vital importancia para ciberseguridad.

Para procesar y coordinar todo este flujo tecnológico, el ecosistema cuenta con herramientas específicas que analizaremos a continuación.

Slide 11: Ecosistema Tecnológico Clave

EXPOSITOR: SEBASTIÁN FERNÁNDEZ RUHL

RESUMEN VISUAL DE SOPORTE: Hadoop, Spark y Kafka en una diapositiva verde lima muy dinámica.

GUIÓN RECOMENDADO:

El ecosistema de Big Data cuenta con herramientas muy variadas, pero se apoya sobre tres tecnologías clave:

- *Apache Hadoop: El framework fundacional open-source. Resuelve el almacenamiento distribuido con HDFS y el procesamiento por lotes con MapReduce utilizando servidores económicos de hardware estándar.*
- *Apache Spark: Un motor de procesamiento revolucionario. Al realizar todo el procesamiento "in-memory" (en memoria RAM) en lugar de escribir datos intermedios en disco constantemente como Hadoop, logra procesar datos hasta 100 veces más rápido. Es el estándar actual para analítica masiva y machine learning distribuido.*
- *Apache Kafka: El pipeline de mensajería pub-sub que procesa la ingesta en tiempo real. Actúa como un amortiguador capaz de absorber de forma distribuida millones de eventos por segundo para alimentar a Spark o Hadoop.*

Veamos ahora en detalle cómo se coordinan estas piezas a nivel de arquitectura y procesamiento.

Slide 12: Procesamiento Distribuido y HDFS

EXPOSITOR: SEBASTIÁN FERNÁNDEZ RUHL

RESUMEN VISUAL DE SOPORTE: Procesamiento en 4 fases de MapReduce y la arquitectura NameNode/DataNode en HDFS.

GUIÓN RECOMENDADO:

Este es el corazón de la materia a nivel de infraestructura distribuida. ¿Cómo logramos almacenar y procesar Petabytes?

Primero, a través de HDFS (el sistema de archivos distribuido de Hadoop). HDFS divide archivos masivos en bloques de 128 Megabytes y los reparte en el clúster. Para lograr tolerancia a fallos, HDFS replica cada bloque 3 veces en nodos distintos. Si un disco o un nodo físico se rompe, los datos siguen a salvo. La coordinación la realiza un NameNode maestro y los bloques son guardados en DataNodes esclavos.

Segundo, a través del paradigma MapReduce, que procesa estos bloques en cuatro fases:

- 1. Split: Se dividen los bloques de datos de entrada.*
- 2. Map: Cada nodo procesa en paralelo su propio fragmento de forma local. Es el concepto de "Data Locality": el código de ejecución viaja al nodo donde está el dato, evitando transferir Gigabytes por la red local.*
- 3. Shuffle: Se ordenan y agrupan los resultados intermedios clave-valor.*
- 4. Reduce: Se consolidan los valores finales en un archivo final unificado.*

A continuación, Santino nos mostrará el impacto y la escala real de estos conceptos.

Slide 13: La Escala Real y Casos de Uso

EXPOSITOR: SANTINO CATALDO

RESUMEN VISUAL DE SOPORTE: Tres tarjetas de impacto (221 ZB, YouTube, Google), cita de ingeniería de hardware/software, y lista de 5 casos de uso.

GUIÓN RECOMENDADO:

Para cerrar la parte de impacto antes de pasar a las conclusiones de Sebastián, queremos ver la escala real de la que estamos hablando con datos cotidianos de hoy en día:

- A nivel global, producimos 221 Zettabytes al año. Pero bajémoslo a tierra: cada día se suben 720.000 horas de video a YouTube y se realizan más de 3.500 millones de búsquedas en Google. Procesar y almacenar esta marea constante de información no es opcional: es lo que mantiene funcionando a los gigantes tecnológicos de hoy.*
- Esto nos lleva a una frase que resume nuestro TP: la arquitectura distribuida no es un capricho o una elección de diseño elegante, sino una necesidad absoluta de ingeniería de hardware y software.*
- En el panel derecho vemos dónde impacta esto en la vida real. En Salud, permite el diagnóstico asistido por IA y el análisis genómico; en Finanzas, la detección de fraudes en milisegundos y el scoring crediticio; en E-Commerce, los motores de recomendación de Amazon o Netflix; en Smart Cities, el control inteligente de tráfico; y en Agro-Tech, la agricultura de precisión basada*

en sensores IoT.

Ahora sí, le cedo la palabra a Sebastián para que presente nuestras conclusiones y el cierre de la presentación.

Slide 14: Conclusiones y Cierre de la Presentación

EXPOSITOR: SEBASTIÁN FERNÁNDEZ RUHL

RESUMEN VISUAL DE SOPORTE: Bloque "¡GRACIAS!" en verde lime y takeaways claves de la investigación.

GUIÓN RECOMENDADO:

Gracias, Santino. Como conclusiones finales del grupo:

- 1. Los RDBMS tradicionales y las infraestructuras de Big Data coexisten y se complementan; no se anulan. Cada uno responde a un desafío de ingeniería diferente.*
- 2. El éxito de cualquier implementación no radica en recolectar información de forma pasiva, sino en la capacidad técnica de procesarla y extraer Valor accionable.*
- 3. La ética, la privacidad y la correcta anonimización en el cruce de datos masivos es una responsabilidad legal y profesional ineludible en nuestra carrera.*

Muchas gracias por su atención. Ahora, para consolidar estos conceptos teóricos de forma interactiva con el curso, queremos invitarlos a participar de una experiencia gamificada inmersiva: un Escape Room de Big Data titulado "Pánico en el Clúster: Rescatando VitalData". En este simulador de contingencia en tiempo real, pondremos a prueba al curso resolviendo la desincronización física de HDFS en el NameNode, ordenando la tubería paralela de MapReduce y, finalmente, enfrentándonos al dilema ético de la desanonimización de registros clínicos cruzados. ¡Prepárense para ingresar al sistema!

3. Guión para la Actividad Interactiva (ejercicio.html)

El ejercicio interactivo se presenta como un "Escape Room" gamificado de 3 niveles en tiempo real. Se coordinará de la siguiente manera:

Nivel 1: Terminal del NameNode Maestro (Coordinación de Santino Cataldo): Santino asume el control inicial y presenta la crisis: los metadatos de HDFS están corruptos y reportan un bloque clínico bloqueado de 8.192 Terabytes. Santino convoca a la clase a calcular cuántos Petabytes (PB) representa esta escala utilizando el multiplicador académico binario de 1.024. Una vez que los estudiantes calculan y responden correctamente que equivale a 8 PB ($8.192 / 1.024$), Santino ingresa el código "8" en el teclado numérico brutalista interactivo en pantalla y pulsa "Enviar Código" para estabilizar el NameNode e inicializar la Tubería Kafka.

Nivel 2: Secuenciador de la Tubería Kafka (Coordinación de Sebastián Fernández Ruhl): Sebastián toma el mando para solucionar el desbordamiento de la ingesta en tiempo real. Explica que el pipeline MapReduce que procesa los registros médicos está desordenado. Pide la participación activa de los alumnos para establecer el flujo lógico correcto de ingeniería: 1. Split, 2. Map, 3. Shuffle & Sort, y 4. Reduce. A medida que el curso propone el orden, Sebastián interactúa con el proyector utilizando los botones de flechas (arriba/abajo) para reordenar las tarjetas interactivas. Al finalizar, hace clic en "Estabilizar Tubería Kafka" y avanzan al Nivel 3.

Nivel 3: Desanonimización y Llave Ética de VitalData (Coordinación Conjunta y Debate): Ambos expositores coordinan este clímax ético. Santino explica la brecha: el clúster ha iniciado un protocolo automático de bloqueo de seguridad (Lockdown) debido a una filtración de datos de pacientes. Para desactivarlo antes de que el sistema destruya o bloquee los registros médicos, el DBA de guardia debe realizar una auditoría forense digital y hallar la clave criptográfica. Santino presenta la búsqueda técnica: una consulta (JOIN distribuido) que cruza los metadatos públicos de geolocalización e IoT a las 10:00 AM con la base de datos "anónima" del hospital. A indicación de los alumnos, Sebastián interactúa con el panel de detalles biométricos. Al seleccionar el Perfil #221, los alumnos analizan los datos crudos y presionan "Cruzar Metadatos". Tras una simulación de carga del clúster, se revela al paciente desanonimizado (Carlos Menem) y se genera la Llave Maestra criptográfica "DBA_ETICA_2026", la cual demuestra al sistema que el DBA ha auditado y controlado la brecha. Santino ingresa la llave para estabilizar VitalData definitivamente. Inmediatamente, abren el debate ético al aula: ¿Es lícita la monetización de datos de salud bajo T&C ilegibles? ¿Qué responsabilidad legal (Ley 25.326) y ética asume un DBA al exportar registros supuestamente anónimos que resultan re-identificables al cruzarse con metadatos externos?

4. Escudo Protector contra Preguntas del Docente (Q&A)

En caso de que el profesor de la materia realice preguntas de control técnicas al finalizar la exposición, aquí se presentan las respuestas de alto nivel estructuradas para lucirse y quién las debe responder:

Pregunta 1: ¿Por qué los JOINS distribuidos destruyen el rendimiento de un clúster relacional?

Responde Santino Cataldo:

Porque las bases de datos relacionales tradicionales asumen que los datos están almacenados en el mismo espacio de disco o memoria. En un clúster distribuido, para unir la Tabla A en el Servidor 1 con la Tabla B en el Servidor 2, el motor síncrono tiene que enviar Gigabytes de datos a través de la red local física para comparar fila por fila en tiempo de ejecución. El ancho de banda de la red física se convierte en el cuello de botella de hardware y el rendimiento cae drásticamente. Por eso, en Big Data y NoSQL preferimos desnormalizar los datos de antemano o utilizar técnicas de localidad de datos (Data Locality).

Pregunta 2: Explicame físicamente cómo Hadoop y HDFS manejan la tolerancia a fallos ante la caída física de un nodo.

Responde Sebastián Fernández Ruhl:

HDFS trabaja con un factor de replicación 3 por defecto. Al guardar un archivo masivo, HDFS lo divide en bloques de 128 MB. El NameNode (nodo maestro de metadatos) le ordena a tres DataNodes esclavos distintos guardar una copia de cada bloque. Los DataNodes envían continuamente una señal de latido (Heartbeat) de red al NameNode indicando que están activos. Si un nodo falla y el NameNode deja de recibir su heartbeat, el NameNode consulta sus metadatos, detecta cuáles bloques estaban alojados en ese nodo caído, localiza las copias sobrevivientes en otros nodos de respaldo y le ordena a un tercer nodo saludable hacer una nueva copia síncrona. De esta manera, el sistema re-establece la replicación 3x de forma automática y transparente sin interrumpir las consultas del usuario.

Pregunta 3: ¿Qué diferencia técnica hay en el uso de la memoria entre Apache Spark y MapReduce?

Responde Sebastián Fernández Ruhl:

La diferencia fundamental reside en las operaciones de Entrada y Salida (E/S) en disco. MapReduce es un paradigma basado en disco: el resultado de cada fase Map se escribe en disco, se lee de allí para el Shuffle, y el resultado del Reduce se vuelve a escribir en almacenamiento físico. En pipelines de varios pasos, esto satura los canales de lectura/escritura de disco. Apache Spark, en cambio, utiliza estructuras de datos lógicas llamadas RDDs (Resilient Distributed Datasets) y mantiene los datos directamente en la memoria RAM de los nodos ejecutores a lo largo de todo el pipeline de análisis. Solo escribe en disco cuando es estrictamente necesario o al guardar el resultado consolidado final, lo que le permite ser hasta 100 veces más rápido que Hadoop.

Pregunta 4: ¿Qué significa consistencia eventual (BASE) en contraste con la consistencia ACID tradicional?

Responde Santino Cataldo:

El modelo ACID tradicional exige consistencia inmediata: una vez que una transacción se escribe, cualquier lectura en cualquier nodo de la base de datos debe ver exactamente ese mismo dato actualizado de forma síncrona, bloqueando las escrituras en caso de fallos. El modelo BASE (Basically Available, Soft state, Eventual consistency), en cambio, asume que en arquitecturas distribuidas masivas, para mantener la alta disponibilidad y la tolerancia a particiones de red (según el Teorema de CAP), no es viable forzar una actualización síncrona de todos los nodos al mismo milisegundo. El sistema BASE garantiza que el clúster estará disponible y que, eventualmente, en el transcurso de milisegundos o pocos segundos, las actualizaciones se propagarán por la red y todos los nodos convergerán al mismo valor de forma asíncrona.